

**ΟΙΚΟΝΟΜΙΚΟ  
ΠΑΝΕΠΙΣΤΗΜΙΟ  
ΑΘΗΝΩΝ**



ATHENS UNIVERSITY  
OF ECONOMICS  
AND BUSINESS

ΣΧΟΛΗ  
ΕΠΙΣΤΗΜΩΝ &  
ΤΕΧΝΟΛΟΓΙΑΣ  
THE  
ΠΛΗΡΟΦΟΡΙΑΣ  
SCHOOL OF  
INFORMATION  
SCIENCES &  
TECHNOLOGY

ΤΜΗΜΑ  
ΣΤΑΤΙΣΤΙΚΗΣ  
DEPARTMENT OF  
STATISTICS

**ΟΙΚΟΝΟΜΙΚΟ ΠΑΝΕΠΙΣΤΗΜΙΟ ΑΘΗΝΩΝ**  
**ΤΜΗΜΑ ΣΤΑΤΙΣΤΙΚΗΣ**

**Μεταπτυχιακό Πρόγραμμα Συμπληρωματικής Ειδίκευσης  
Εφαρμοσμένη Στατιστική**

**Μάθημα: Υπολογιστική Στατιστική  
Computational Statistics**

**Ημερομηνία Παράδοσης εργασίας: 4/2/2020**

**Κωνσταντίνα Τσάμη**

## PAPER 1

### Task 1

Το ζητούμενο της πρώτης άσκησης της εργασίας αυτής είναι να αναπτύξουμε δύο συναρτήσεις στην R που να υπολογίζουν τη δειγματική διακύμανση  $s^2$ . Η μία συνάρτηση θα την υπολογίζει μέσω του τύπου που την ορίζει και η δεύτερη βασίζεται στον τύπο υπολογισμού με το χέρι.

Για την πρώτη συνάρτηση(formation definition) εφαρμόζουμε τον τύπο της μεροληπτικής διακύμανσης  $\Sigma(x_i - \mu)^2 / n$ , ενώ για τη δεύτερη(hand calculation equation) τον τύπο της αμερόληπτης(unbiased) διακύμανσης  $\Sigma(x_i - \mu)^2 / (n-1)$ . Γνωρίζουμε ότι για μεγάλο δείγμα προσεγγίζει την ακρίβεια της αμερόληπτης διασποράς, για αυτό και στις δύο συναρτήσεις θα χρησιμοποιήσουμε μεγάλο μέγεθος δείγματος.

Η διαδικασία που ακολουθούμε και για τις δύο συναρτήσεις είναι παρόμοια.

Αρχικά θα παράγεται μέσα στη συνάρτηση τυχαίο δείγμα από κανονική κατανομή με μέσω τυπική απόκλιση και μέγεθος δείγματος τα οποία είναι τα “arguments” της συνάρτησης μας και στη συνέχεια θα υπολογίζεται το  $s^2$  αυτού του δείγματος.

Για τον υπολογισμό λοιπόν της  $s^2$  μέσω του “formation definition” ο κώδικας που εφαρμόζουμε είναι:

**#function 1 using the formation definition**

```
vardc<-function(n,mn=0,vr=1) {  
  x<-rnorm(n,mn,vr)  
  v<-0  
  m<-mean(x)  
  for (i in 1:n ) {  
    v<-v+(x[i]-m)^2  
  }  
  var<-v/(n)  
  return(var)  
}
```

Ενώ, για τον υπολογισμό της  $s^2$  μέσω του “hand calculation equation” είναι:

#function 2 based on the hand calculation equation

```
varhc<-function(n,mn=0,vr=1) {  
  
  x<-rnorm(n,mn,vr)  
  
  v<-0  
  
  m<-mean(x)  
  
  for (i in 1:n ) {  
  
    v<-v+(x[i]-m)^2  
  
  }  
  
  var<-v/(n-1)  
  
  return(var)  
  
}
```

Δοκιμάζοντας τις δύο συναρτήσεις για ένα μέγεθος δείγματος  $n=10000$  και μία μεγάλη τιμή για μέσο όπως το 1000, για διαφορετικές τυπικές αποκλίσεις.

```
> x<-vardf(10000,1000,200)  
> sqrt(x)  
[1] 200.1545  
> x<-varhc(10000,1000,200)  
> sqrt(x)  
[1] 202.0596  
>  
> x<-vardf(10000,1000,20)  
> sqrt(x)  
[1] 20.78012  
> x<-varhc(10000,1000,20)  
> sqrt(x)  
[1] 19.641
```

Παρατηρούμε ότι για μεγαλύτερη διασπορά δείγματος η πρώτη συνάρτηση(formation definition) είναι πιο κοντά στην πληθυσμιακή-θεωρητική διακύμανση. Ενώ για δείγματα με μικρότερη διασπορά η δεύτερη συνάρτηση είναι σχετικά πιο ακριβής με ελάχιστη διαφορά.

## Task 2

Η δεύτερη άσκηση ζητά να υπολογίσουμε τον εκτιμητή μέγιστης πιθανοφάνειας για την παράμετρο  $\theta_1$  της κατανομής Cauchy και σταθερό  $\theta_2=1$ .

Για να το υλοποιήσουμε θα εφαρμόσουμε τον αλγόριθμο “Newton-Raphson” και συγκεκριμένα μία παραλλαγή του (Newton like method) την “quasi Newton-Raphson”.

Αρχικά εισάγουμε τα δεδομένα μας.

```
x<-c(1.77,-0.23,2.76,3.80,3.47,56.75,-1.34,4.24,-2.44,3.29,3.71,  
-2.40,4.53,-0.07,-1.05,-13.87,-2.53,-1.75,0.27,43.21)
```

Στη συνέχεια θα δημιουργήσουμε τη συνάρτηση που υπολογίζει την log-likelihood της συνάρτησης πυκνότητας πιθανότητας της Cauchy με σταθερό  $\theta_2=1$ .

#log-likelihood function of Cauchy distribution

```
ell <- function(theta){  
  sum(dcauchy(x, location = theta, scale = 1, log = TRUE))  
}
```

Σειρά έχει να εξετάσουμε την συμπεριφορά της λογαριθμικής πιθανοφάνειας μέσω του κατάλληλου γραφήματος.

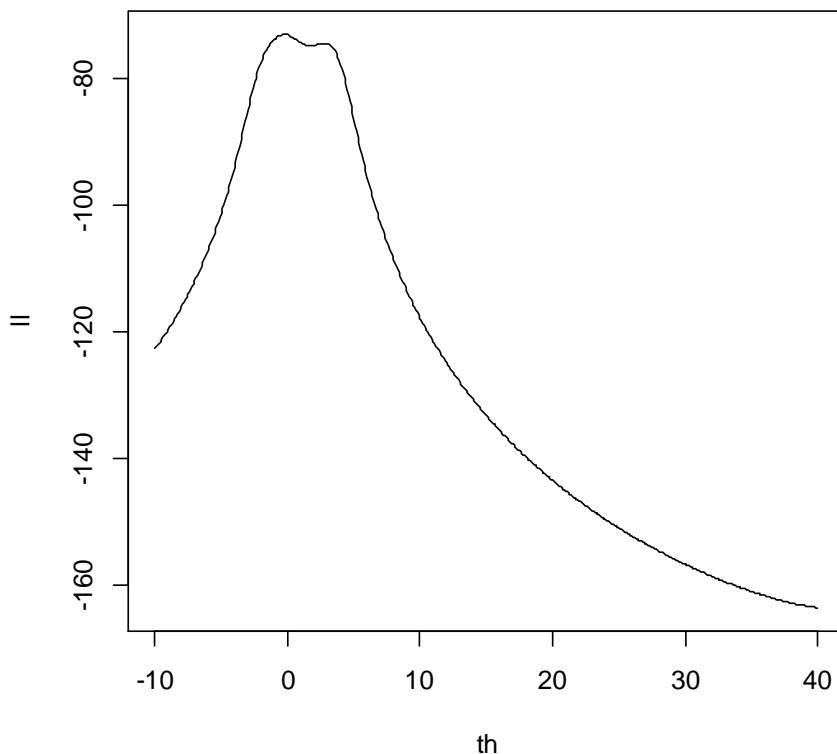
#plot of the log-likelihood function:

```
th<-seq(-10,40,0.1)  
ll<-numeric(length(th))  
for (i in 1:length(th)) {  
  ll[i]<-ell(th[i])  
}  
plot(th,ll,type='l',main="Cauchy Log-Likelihood function")
```

Όπως παρατηρούμε στο Διάγραμμα 1 πιο κάτω, η log-likelihood φαίνεται να παρουσιάζει ολικό μέγιστο για  $\theta_1$  γύρω στο 0, ενώ παρουσιάζει και ένα τοπικό μέγιστο για  $\theta_1$  κοντά στο 3.

### Διάγραμμα 1 - Log-Likelihood plot

#### Cauchy Log-Likelihood function



Θα βρούμε τον MLE εκτιμητή του  $\theta_1$  δοκιμάζοντας διάφορα starting points στον αλγόριθμό μας.

#### #quasi NR

Διαβάζουμε τη βιβλιοθήκη για το πακέτο που θα χρησιμοποιήσουμε για τους υπολογισμούς των παραγόγων.

```
library(numDeriv)
```

Το -11 και 8 δεν είναι καλά σημεία εκκίνησης καθώς ο αλγόριθμός μας δε συγκλίνει.  
Δοκιμάζουμε όλα τα υπόλοιπα starting points καθώς επίσης και την διάμεσο των δεδομένων.

```
theta0<-c(-1,0,1.5,4,4.7,7,38,mean(x),median(x)) #starting value
```

```
theta<-numeric(length(theta0))
```

```
for (i in 1:length(theta0)) {
```

```
eps <- 1 #cvge criterion
```

```
while (eps>1e-6){
```

```
elldash<- grad(ell,theta0[i]) #first derivative
```

```

elldash <- hessian(ell,theta0[i])[1,1] #second derivative

theta[i] <- theta0[i] - elldash/elldash

eps <- abs(theta[i]-theta0[i])

theta0[i] <- theta[i]

}

}

```

```
cbind(starting.point=round(c(-1,0,1.5,4,4.7,7,38,mean(x),median(x)),1),theta)
```

	starting.point	theta
[1, ]	-1.0	<span style="color:red">-0.1922866</span>
[2, ]	0.0	<span style="color:red">-0.1922866</span>
[3, ]	1.5	1.7135868
[4, ]	4.0	2.8174722
[5, ]	4.7	<span style="color:red">-0.1922866</span>
[6, ]	7.0	41.0408478
[7, ]	38.0	42.7953775
[8, ]	5.1	<span style="color:blue">56.2533580</span>
[9, ]	1.0	1.7135868

Παρατηρούμε ότι ο μέσος (8<sup>η</sup> σειρά ) δεν είναι ένα καλό σημείο εκκίνησης καθώς απέχει πολύ από την εκτίμηση που μεγιστοποιεί την συνάρτησή μας. Αυτό συμβαίνει διότι στην περίπτωση της Cauchy οι παράμετροι δεν περιγράφουν τον μέσο και την τυπική απόκλιση όπως στην κανονική κατανομή. Δοκιμάσαμε σαν starting point και τη δειγματική διάμεσο η οποία δίνει καλύτερη εκτίμηση(9<sup>η</sup> σειρά).

Σε γενικές γραμμές τα καλύτερα σημεία εκκίνησης είναι το -1,0 αλλά και το 4 ε.μ.π. ίσο με -0.19. Γενικά προτιμούμε να εισάγουμε σημεία εκκίνησης όσο γίνεται πιο κοντά στο μέγιστο.

## **PAPER 1**

### **Task 1**

Θα υπολογίσουμε τους πιο εκτιμητές λ, α, κ της Γενικευμένης Γάμμα κατανομής.

Αρχικά περνάμε τα δεδομένα μας με τους χρόνους διάρκειας κύησης.

**y<-c(2.1,4,2.6,1.5,2.5,4,2,**

**3.4,4.1,3.6,4.7,2.5,4,2.7,**

**4.25,5,3.6,4.7,3.4,5.25,2.75,**

**5.6,5.5,6.4,7.2,4.2,6.1,3.4,**

**6.4,5.7,6.8,7.25,5.9,6.5,4.2,**

**7.3,6.5,7.5,8.1,6.25,6.9,4.3,**

**8.5,7.25,7.5,8.5,7.3,7,4.9,**

**8.75,7.3,8.25,9.2,7.5,8.45,6.25,**

**8.9,7.5,8.5,9.5,7.8,9.25,7,**

**9.5,8.2,10.4,10.7,8.3,10.1,9,**

**9.75,8.5,10.75,11.5,8.3,10.2,9.25,**

**10,9.75,14.25,10.25,12.75,10.7,**

**10.4,11,14.5,12.9,14.6,**

**10.4,11.2,14.3,**

**16,15,**

**19,16.5)**

Στη συνέχεια θα δημιουργήσουμε τη συνάρτηση της αρνητικής λογαριθμικής πιθανοφάνειας με την παρακάτω παραμετροποίηση:

- $a = \ln(\alpha)$
- $k = \ln(\kappa)$
- $l = \ln(\lambda)$

```

#minus log likelihood function

negloglikgengamma<-function(theta,dat){

  a<-theta[1]

  k<-theta[2]

  l<-theta[3]

  n<-length(dat)

  -(n*a+n*exp(k)*l-n*log(gamma(exp(k)))+(exp(a)*exp(k)-1)

  *sum(log(dat))-exp(l)*sum(dat^exp(a)))

}

```

Θα χρησιμοποιήσουμε τη συνάρτηση *optim* της R η οποία εφαρμόζει τη μέθοδο Newton-Raphson για την εύρεση ελαχίστου. Ελαχιστοποιώντας την αρνητική λογαριθμική πιθανοφάνεια μεγιστοποιούμε την λογαριθμική πιθανοφάνεια και ως εκ τούτου την πιθανοφάνεια της Γενικευμένης Γάμμα.

Σαν σημεία εκκίνησης θα χρησιμοποιήσω τα (a,k,l)=(-100,-100,-100)

```

fitggamma<-optim(c(-100,-100,-100),negloglikgengamma,hessian=TRUE,method="BFGS",dat=y)

```

Κατασκευάζουμε τον πίνακα με τις εκτιμήσεις των παραμέτρων και τα τυπικά σφάλματα των εκτιμητών που μας έδωσε σαν αποτέλεσμα η *optim*.

```

ggammamle<-cbind(est=fitggamma$par, se=sqrt(diag(solve(fitggamma$hessian))))

```

**ggammamle**

	est	se
[1, ]	1.652433	0.1184858
[2, ]	-1.211966	0.2042144
[3, ]	-13.405832	1.7949182

- Η εκτίμηση της παραμέτρου  $a = \ln(\alpha)$  είναι 1.65 με τ.σ. ίσο με 0.11.
- Η εκτίμηση της παραμέτρου  $k = \ln(\kappa)$  είναι -1.21 με τ.σ. ίσο με 0.2.
- Η εκτίμηση της παραμέτρου  $l = \ln(\lambda)$  είναι -13.4 με τ.σ. ίσο με 1.79.

Παρατηρούμε ότι έχουμε μικρά τυπικά σφάλματα, κάτι πολύ θετικό.

Για τις εκτιμήσεις των  $\alpha, \kappa, \lambda$ :

```

round(exp(ggammamle),4)

```

```
      est      se
[1,] 5.2197 1.1258
[2,] 0.2976 1.2266
[3,] 0.0000 6.0190
```

Τώρα, για να κατασκευάσουμε και ένα 95% διάστημα εμπιστοσύνης των εκτιμητών.

```
CI<-cbind(LCI=ggammamle[,1]-
1.96*ggammamle[,2],UCI=ggammamle[,1]+1.96*ggammamle[,2])
exp(CI)
```

```
      LCI          UCI
[1,] 4.118386e+00 6.615429e+00
[2,] 1.978206e-01 4.477424e-01
[3,] 4.157909e-08 5.457168e-05
```

## Task 2

Αρχικά θα φτιάξω την αρνητική λογαριθμική πιθανοφάνεια της γενικευμένης Γάμμα για fixed τιμές των  $k, l$  ίσες με τις mle εκτιμήσεις τους που βρήκαμε προηγουμένως.

#minus log likelihood function for alpha

```
negloglikgg<-function(alpha,dat) {
```

```
    a<-alpha
```

```
    k<-ggammamle[2,1]
```

```
    l<-ggammamle[3,1]
```

```
    n<-length(dat)
```

```
    -(n*a+n*exp(k)*l-n*log(gamma(exp(k)))+(exp(a)*exp(k)-1)
```

```
*sum(log(dat))-exp(l)*sum(dat^exp(a)))
```

```
}
```

Αυτό το κάναμε με σκοπό να χρησιμοποιήσουμε τη συνάρτηση αυτή ώστε σε κάθε νέο δείγμα που θα προσομοιώνουμε με τη συνάρτηση της γενικευμένης γάμμα με τις εκτιμήσεις των παραμέτρων που βρήκαμε στο προηγούμενο βήμα, να υπολογίζουμε εκ νέου ένα νέο εκτιμητή για το  $a$  στα προσομοιωμένα δεδομένα.

Για την προσομοίωση θα εφαρμόσουμε τη μέθοδο της αντιστοφής.

Διαβάζουμε τη βιβλιοθήκη για τη συνάρτηση που μας βοηθάει στην αντιστροφή των συναρτήσεων.

**library(GoFKernel)**

Ορίζω την αντίστροφη συνάρτηση που θα χρησιμοποιήσω.

```
F.x<-function(x) {integrate(gg.pdf,lower=0,x)$value}
```

```
f.x<-inverse(F.x,lower=0)
```

Ξεκινάω τη προσομοίωση υπολογίζοντας την εκτίμηση για τη παράμετρο  $a$  (thetastar) για κάθε ένα από τα 800 τυχαία δείγματα που θα παράγω από την κατανομή μου.

```

the tастar <- numeric(800)

thet<- 0

for (i in 1:800){

  #generating random samples from my distribution

  xstar<-numeric(95)

  u<-0

  for (j in 1:95) {

    u<-runif(1)

    xstar[j]<-f.x(u)

  }

#ektimhsh gia to θ1

  the t<-optim(-100,negloglikgg,hessian=TRUE,method="BFGS",dat=xstar)

  the tастar[i]<-thet$par

}


```

Για την εκτίμηση του bootstrap διαστήματος εμπιστοσύνης θα χρησιμοποιήσω τα ποσοστιαία σημεία της κατανομής της thetastar.

```

up<-quantile(the tастar, probs = 0.975)

lr<-quantile(the tастar, probs = 0.025)

```

**CIBoot<-cbind(LCI=lr,UCI=up) #0.47 polu ektos twn diasthmatwn bootstrap - oxi kaih prosarmogh**

**CIBoot**

**ggammamle[1,1]**

Τα αποτελέσματα που έχω για το 95% διάστημα εμπιστοσύνης με την παραμετρική μέθοδο του bootstrap για το  $a = \ln(\alpha)$  είναι:

```
> CIBoot
      LCI      UCI
2.5% 1.253883 1.3097
```

Η εκτίμηση που είχαμε είναι:

```
> ggammamle[1,1]
      est
1.652433
```

Παρατηρώ ότι η εκτίμησή μου δεν είναι μέσα στο διάστημα εμπιστοσύνης της bootstrap.

Επομένως, η Γενικευμένη Γάμμα δεν προσαρμόζεται καλά στα δεδομένα.

### Task 3

Προσαρμόζω την αρνητική λογαριθμική πιθανοφάνεια της Εκθετικής κατανομής κρατώντας την παραμετροποίηση  $l = \ln(\lambda)$ .

```
minusellexp <- function(lambda,dat) {  
  #exponential minus log-likelihood  
  n <- length(dat)  
  -n*lambda+exp(lambda)*sum(dat)  
}
```

Βρίσκω τον εκτιμητή μέγιστης πιαθνοφάνειας για τον  $l$ .

```
fitexp <- optim(0.5, minusellexp, method='BFGS', dat=y, hessian=T)  
fitexp
```

```
list(estim=fitexp$par,st.er.=sqrt(solve(fitexp$hessian)))
```

```
$estim  
[1] -2.044224  
  
$st.er.  
[ , 1 ]  
[1, ] 0.1025978
```

Η εκτίμηση του  $l$  είναι -2.04 με τυπικό σφάλμα 0.1

To LR test έχει τιμή ελεγχοσυνάρτησης  $LR = -2\log(l_1 - l_2)$  όπου  $l_1, l_2$  λογαριθμικές πιθανοφάνειες των ε.μ.π. εκτιμητών.

Στα δεδομένα μας η τιμή αυτή δίνεται μέσω της μέγιστης τιμής των log-likelihood της γενικευμένης γάμμα και της εκθετικής που πρασαρμόσαμε.

```
lr.t<- -2*(fitggamma$value - fitexp$value)
```

```
lr.t
```

```
[1] 62.58248
```

Για τη Μέθοδο Monte Carlo και τον έλεγχο Υποθέσεων likelihood ratio θα προσομοιώσουμε δείγματα μέσω της μη παραμετρικής bootstrap παράγοντας 1000 τυχαία δείγμα από τα δεδομένα μας, με επανατοποθέτηση.

Για κάθε νέο δείγμα υπολογίζουμε εξ αρχής τις παραμέτρους ε.μ.π. των δύο πιθανοφανειών και στη συνέχεια την ελεγχοσυνάρτηση LR.

### **lrt <- numeric(1000)**

```
for (r in 1:1000) {
  x<-sample(y, replace=T)
  fit1<-optim(c(-100,-100,-100),negloglikgengamma,method="BFGS",dat=x)
  fit2<-optim(0.5,minusellexp,method="BFGS",dat=x)
  l1<-fit1$value
  l2<-fit2$value
  lrt[r] <- -2*(l2-l1)
}
```

Συγκρίνοντας τα  $1-\alpha$  ποσοστιαία σημεία της  $X^2$  κατανομής με αυτά της κατανομής της lrt έχουμε:

	80%	90%	95%	99%
simulated	64.013719	69.51460	75.809318	95.33950
chisq	3.218876	4.60517	5.991465	9.21034

Όπως βλέπουμε η lrt δεν προσαρμόζεται καλά στα ποσοστιαία σημεία της  $X^2$  κατανομής με 2 βαθμούς ελευθερίας (προκύπτουν από τη διαφορά στον αριθμό των παραμέτρων των 2 πιθανοφανειών).

Υπολογίζουμε το p-value της Monte Carlo.

### **#Monte Carlo p value**

```
(sum(lrt>lr.t)+sum(lrt<-lr.t))/1000
```

```
[1] 0.08458248
```

Υπάρχουν επαρκείς ενδείξεις ότι μπορούμε να απορρίψουμε την μηδενική υπόθεση της μη ύπαρξης σημαντικών διαφορών ανάμεσα στις δύο πιθανοφάνειες σε επίπεδο  $\alpha=10\%$ .

Επομένως η προσαρμογή της εκθετικής κατανομής προσαρμόζεται καλύτερα στα δεδομένα. Στο ίδιο συμπέρασμα οδηγούμαστε και ασυμπτωματικά ( $LR=62.58 > X^2_{0.95}=5.99$ ).

## Task 4

Για την εκτίμηση της πιθανότητας η διάρκεια κύησης να μην ξεπερνά τις 10 ώρες  $P(X \leq 10)$  θα προσομοιώσω δείγματα από την εκθετική κατανομή με την εκτίμηση της παραμέτρου που είχαμε. Σε κάθε νέο σετ δεδομένων θα εκτιμήσουμε από την αρχή την ε.μ.π. παράμετρο της εκθετικής και στη συνέχεια την πιθανότητα που ζητούμε να υπολογίσουμε.

```
n <- 95; lamda <- exp(fitexp$par)

prob <- numeric(1000)

for (r in 1:1000){

  x <- rexp(n, lamda)

  lambdas tar<-optim(0.5, minus ellexp, method='BFGS', dat=x, hessian=F)$par

  fx<-function(x) {dexp(x,exp(lambdas tar))}

  prob[r] <- integrate(fx,0,10)$value

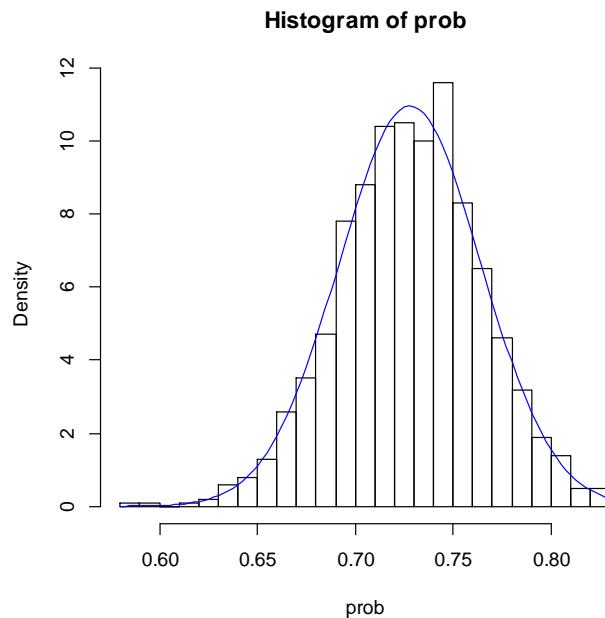
}
```

Από το ιστόγραμμα φαίνεται ότι η κατανομή της εκτίμησης της πιθανότητας προσεγγίζει τη κανονική και επομένως η τυπική απόκλιση θα μας δώσει και το standard error της εκτίμησης αυτής.

```
hist(prob,25,prob=T)

curve(dnorm(x,mean(prob),sd(prob)),col="blue",add=T)
```

Διάγραμμα 2: ιστόγραμμα κατανομής εκτίμησης της πιαθνότητας



Το τυπικό σφάλμα θα είναι

#se gia th pithanothta

**sd(prob)**

[1] 0.03635842

Η εκτίμηση της πιθανότητας στα δεδομένα μας θα είναι:

**f<-function(x) {dexp(x,exp(fitexp\$par))}**

**pr <- integrate(f,0,10)\$value**

**pr**

[1] 0.7260492

Η πιθανότητα η διάρκεια κύησης να μην ξεπερνά τις 10 ώρες είναι 72% με τυπικό σφάλμα 0.04.

## PAPER 3

### Task 1

Θα εφαρμόσουμε μέθοδο αντιστροφής για να προσομοιώσουμε την οριακή κατανομή πιθανότητας που μας ζητείται

**library(GoFKernel)**

Ορίζω την αντίστροφη συνάρτηση.

**f<-function(t){4\*(1-t)/(^3)}**

**F<-function(x) {integrate(f,lower=0,x)\$value}**

**F.inv<-inverse(F,0,1)**

Τρέχω τη προσομοίωση

**xsim<-numeric(100)**

**u<-0**

**for (r in 1:100) {**

**u<-runif(1)**

**xsim[r]<-F.inv(u)**

**}**

### Task 2

Θα εφαρμόσουμε μέθοδο αντιστροφής για να προσομοιώσουμε την και τη δεσμευμένη σ.π.π.  $f(y/x)$  για δεδομένο  $x$ .

**x<-0.05**

**f<-function(t){6\*x\*(1-t-x)/(1-t)^3}**

**F<-function(x) {integrate(f,lower=0,x)\$value}**

```
F.inv<-inverse(F,0,0.95)
```

```
z<-seq(0,0.95,0.01)
```

```
Fx<-numeric(length(z))
```

```
for (i in 1:length(z) ) {
```

```
    Fx[i]<-F(z[i])
```

```
}
```

```
plot(z,Fx,type='l',main='plot of cdf')
```

```
#h f(x) einai "1-1" ara kai antistrepsimh
```

```
#mporw na xrhs imopoihs w methodo antistrofhs
```

```
ysim<-numeric(100)
```

```
u<-0
```

```
for (r in 1:100) {
```

```
    u<-runif(1)
```

```
    ysim[r]<-F.inv(u)
```

```
}
```

### Task 3

Για να προσομοιώσουμε από την από κοινού κατανομή  $f(x,y)$  θα χρησιμοποιήσουμε την δεσμευμένη και την οριακή σ.π.π.

$$f(x_i, y_i) = f(y_i/x_i) f(x_i)$$

Για κάθε  $x_i$  από τα προσομοιωμένα που έχουμε στην άσκηση 1 θα προσομοιώσουμε ένα για από τη δεσμευμένη  $f(y_i/x_i)$  και έτσι θα φτιάξουμε τα ζεύγη  $(x_i, y_i)$  της από κοινού σ.π.π.

```
ysim<-numeric(100)
```

**u<-0**

**u<-0**

**x<-0**

**for (r in 1:100) {**

**x<-simx[r]**

**f<-function(t){6\*x\*(1-t-x)/(1-t)^3}**

**F<-function(x) {integrate(f,lower=0,x)\$value}**

**F.inv<-inverse(F,0,1-x)**

**u<-runif(1)**

**ysim[r]<-F.inv(u)**

**}**

Τα προσομοιωμένα δείγματα θα είναι.

```
> ysim
 [1] 0.25657153 0.18858781 0.40341893
 [4] 0.34428373 0.52416215 0.28413545
 [7] 0.40995972 0.39664646 0.20071505
 [10] 0.29266410 0.09806468 0.49080025
 [13] 0.42764432 0.39465805 0.22858870
 [16] 0.40500185 0.29673073 0.27094994
 [19] 0.21409959 0.21730315 0.39414440
 [22] 0.38505229 0.15411813 0.33081147
 [25] 0.34335174 0.47535475 0.31293036
 [28] 0.34294495 0.18688316 0.40439238
 [31] 0.36752119 0.30534197 0.46557585
 [34] 0.37457578 0.47753220 0.18055995
 [37] 0.44083254 0.37991373 0.41257170
 [40] 0.32500980 0.23316776 0.27544408
 [43] 0.40506798 0.35098148 0.19119075
 [46] 0.30433999 0.42382864 0.37770301
 [49] 0.45504544 0.30081634 0.08240706
 [52] 0.42435443 0.43146274 0.39442426
 [55] 0.37594636 0.42551697 0.35541234
 [58] 0.30939815 0.36265904 0.26122277
 [61] 0.15386086 0.31234592 0.38729182
 [64] 0.24332821 0.24364501 0.54418321
 [67] 0.20018026 0.01718968 0.48719617
 [70] 0.25084871 0.24226657 0.13912957
 [73] 0.29953239 0.03064699 0.44667175
 [76] 0.27991735 0.37269096 0.41589335
 [79] 0.39969639 0.41940040 0.38750575
 [82] 0.43909857 0.37993818 0.40562992
```

```

[85] 0.29496843 0.39518716 0.26194819
[88] 0.18376913 0.37357969 0.39257271
[91] 0.20054446 0.40689905 0.26716015
[94] 0.38516698 0.38228143 0.47931303
[97] 0.45048284 0.12619894 0.58489878
[100] 0.46377580

> xsim
[1] 0.022771285 0.006496715 0.250418677 0.052160704
[5] 0.352008021 0.147784778 0.344371326 0.228532415
[9] 0.111236446 0.235140082 0.505453173 0.408519221
[13] 0.340661785 0.058312134 0.143773909 0.086430341
[17] 0.028665506 0.287174740 0.439267227 0.083469562
[21] 0.064023430 0.084237038 0.054907510 0.077951013
[25] 0.260125939 0.307700296 0.030912502 0.102454530
[29] 0.244896842 0.460953636 0.146417036 0.098091147
[33] 0.212965726 0.371159256 0.404636399 0.133274646
[37] 0.179351828 0.036392343 0.164392322 0.413762950
[41] 0.099827131 0.371593124 0.249413916 0.004267682
[45] 0.202761930 0.044023716 0.129986918 0.241907320
[49] 0.227468335 0.246521983 0.179662435 0.076162992
[53] 0.238714027 0.138261155 0.056763230 0.311524147
[57] 0.475804487 0.390772689 0.213189580 0.009578145
[61] 0.264609745 0.324160399 0.068460511 0.138598834
[65] 0.448188122 0.346749262 0.169430401 0.064014356
[69] 0.287858301 0.498345847 0.006550481 0.126130278
[73] 0.041424191 0.517730445 0.278776734 0.019674841
[77] 0.036968196 0.124585920 0.196015610 0.214603844
[81] 0.315909684 0.207748227 0.308528335 0.193083392
[85] 0.009181012 0.471087155 0.058941350 0.114353412
[89] 0.094158646 0.151483923 0.213641151 0.323312513
[93] 0.219956476 0.009426819 0.020132601 0.407701963
[97] 0.202119641 0.145896463 0.374756158 0.367415744

```

Υπολογίζω τον συντελεστή συσχέτισης για X,Y

```

cor(xsim,ysim)
[1] 0.1681808
sqrt(6)/6
[1] 0.4082483

```

Ο συντελεστής συσχέτισης είναι κοντά στο 0 το ίδιο και η θεωρητική τιμή του.

Οι δύο μεταβλητές δεν εμφανίζονται να είναι γραμμικά συσχετισμένες.